

#### TECHNISCHES KONZEPT · PROGNOSEMODELL

## Vom Baseline-Heuristik zum trainierten Modell.

Ein 5-Schritte-Plan, wie wir aus den historischen Daten ein eigenes Prognosemodell trainieren, gegen die naive Basislinie evaluieren und in Betrieb nehmen — inklusive erster echter Backtest-Ergebnisse.

#### MODELL-TRAININGSPLAN · V1

---

**3**

Modellfamilien im Vergleich

**15.600**

Trainingsbeispiele

**+15,5 %**

genauer als Persistenz

---

Stand 18. Juli 2026 · Prototyp · [nicolaslekai.github.io/aeris](https://nicolaslekai.github.io/aeris)

## AUSGANGSLAGE

### Warum ein trainiertes Modell?

Der heutige Prototyp nutzt eine transparente **Persistenz-Basislinie plus Signal-Tilt** — ehrlich, aber regelbasiert. Ein trainiertes Modell lernt die Zusammenhänge zwischen Vorlaufsignalen und ITS-Belegung direkt aus **sechs Jahren Historie** und kann nichtlineare, saisonale und regionale Muster abbilden, die eine feste Regel nicht erfasst.

## WORAUF WIR TRAINIEREN

### Daten & Zielgröße

#### Zielgröße

Wöchentliche mittlere ITS-Belegung je Bundesland, **1–3 Wochen voraus**. Die Belegungsrate = belegte / betreibbare Betten aus dem DIVI-Register.

#### Datenumfang

16 Bundesländer × ~330 Wochen (2020–2026) × 3 Horizonte = **15.600 Trainingsbeispiele**. Alles aus öffentlichen Quellen.

| MERKMALSGRUPPE               | KONKRET                                                      | ROLLE                        |
|------------------------------|--------------------------------------------------------------|------------------------------|
| <b>Autoregressiv</b>         | Belegung Lag 1–4 Wo., 4-Wo.-Mittel & -Trend, Wochendifferenz | stärkster Kurzfristprädiktor |
| <b>ARE-Konsultationen</b>    | Niveau + Momentum je Bundesland (RKI AGI)                    | Wellenform, 1–2 Wo. Vorlauf  |
| <b>SARI-Hospitalisierung</b> | Niveau + Momentum, national (RKI ICOSARI)                    | direkter Zufluss, 3–7 Tage   |
| <b>Saisonalität</b>          | Kalenderwochen-Harmonische (sin/cos, 2 Ordnungen)            | Jahreszyklus                 |
| <b>Region</b>                | Bundesland-Indikator (One-Hot)                               | regionales Niveau            |
| <b>Temperatur (DWD)</b>      | Tagesmittel je Land                                          | V1.1 · GEPLANT               |

**Kein Data-Leakage:** Exogene Signale (ARE/SARI) werden um eine Woche verzögert genutzt, um die reale Meldeverzögerung abzubilden. Das Modell sieht beim Prognosezeitpunkt ausschließlich Information, die dann auch tatsächlich vorlag.

## HARDWARE

### Was wir wirklich brauchen

#### Für den MVP: der Mac genügt

Es sind kleine tabellarische Daten (~15k Zeilen). Alle drei Modelle trainieren in **Sekunden bis Minuten auf der CPU** — keine GPU nötig.

#### RTX 4090 · CUDA: Reserve

Erst relevant für tiefe Sequenzmodelle (z. B. Temporal Fusion Transformer) oder die Ausweitung auf ~400 Landkreise. Headroom für Forschung, keine Voraussetzung.

## DER PLAN

# Fünf Schritte zum eigenen Modell

1

### Daten zusammenführen & Merkmale bilden

DIVI-Belegung, ARE und SARI auf ein wöchentliches Panel je Bundesland ausrichten; autoregressive, saisonale und Signal-Merkmale erzeugen.

Ergebnis: 15.600 lückenbereinigte Beispiele · leakage-sicher (Signale 1 Wo. verzögert).

2

### Drei Modellfamilien trainieren

ElasticNet (regularisiert linear), HistGradientBoosting (Gradient-Boosting-Bäume) und ein kleines neuronales Netz (MLP) — bewusst unterschiedliche Ansätze.

Ein Modell je Familie deckt alle drei Horizonte ab (Horizont als Merkmal).

3

### Ehrlich evaluieren (Backtest)

Training auf 2020–Mitte 2025, Test auf dem **letzten, ungesehenen Jahr**. Metrik: MAE/RMSE der Belegung, bewertet als **Skill gegenüber der Persistenz-Basislinie**.

Rolling-Origin-Prinzip: keine Zukunftsinformation im Training.

4

### Bestes Modell wählen & kalibrieren

Niedrigster Test-MAE gewinnt. Unsicherheitsbänder aus den **empirischen Residuen** des Backtests — statt fester Faustregel.

Ergebnis: kalibrierte Spannen & Überschreitungswahrscheinlichkeit  $P(>85\%)$ .

5

### In Betrieb nehmen

Gewinnermodell auf allen Daten neu trainieren, als Artefakt speichern und in die Pipeline einhängen — das Live-Dashboard nutzt es automatisch.

Nächster Ausbau: tägliche automatische Neuberechnung & Modell-Refresh.



## ERSTE ERGEBNISSE · BEREITS TRAINIERT

### Backtest auf dem ungesehenen letzten Jahr

Der Plan ist nicht nur Theorie — er läuft. Alle drei Modelle wurden trainiert und auf den letzten 52 Wochen getestet, die sie nie gesehen haben. **Alle drei schlagen die Persistenz-Basislinie**; Gradient-Boosting gewinnt.

| MODELL                      |                 | MAE (%-PKT.) | RMSE | SKILL VS. PERSISTENZ | JE HORIZONT 1/2/3  |
|-----------------------------|-----------------|--------------|------|----------------------|--------------------|
| <b>HistGradientBoosting</b> | <b>GEWINNER</b> | <b>1,48</b>  | 2,02 | <b>+15,5 %</b>       | 1,35 / 1,50 / 1,59 |
| ElasticNet                  |                 | 1,56         | 2,12 | +11,3 %              | 1,38 / 1,58 / 1,71 |
| MLP (neuronales Netz)       |                 | 1,60         | 2,20 | +8,6 %               | 1,47 / 1,61 / 1,73 |
| Persistenz (Basislinie)     |                 | 1,75         | —    | —                    | Referenz           |



## EINORDNUNG

### Was die Zahlen bedeuten

- **MAE  $\approx$  1,5 %-Punkte** heißt: die 1-Wochen-Prognose liegt im Mittel rund anderthalb Belegungspunkte daneben — praxistauglich für die Personalplanung.
- **+15,5 % Skill** ist ein ehrlicher, belastbarer Fortschritt: ITS-Belegung ist stark autoregressiv, daher ist Persistenz eine harte Messlatte.
- Das Modell ist **live in Betrieb** — das Dashboard rechnet bereits mit ihm, inklusive empirisch kalibrierter Unsicherheitsbänder.

## ALS NÄCHSTES

### Wie wir den Skill weiter heben

#### Mehr Signal

Temperatur (DWD) und Abwasser (AMELAG) als Merkmale ergänzen; Feiertags-/Ferieneffekte fein modellieren.

#### Bessere Modelle

Quantil-Boosting für native Prognoseintervalle; Walk-Forward-Retraining; bei Bedarf Sequenzmodelle auf der 4090.

### Live ansehen — das Modell rechnet bereits

Alle Zahlen in diesem Dokument stammen aus echten, öffentlich verfügbaren Daten und einem tatsächlich trainierten Modell.

LIVE-DEMO

[nicolaslekai.github.io/aeris](https://nicolaslekai.github.io/aeris)

CODE

[github.com/nicolaslekai/aeris](https://github.com/nicolaslekai/aeris)

KONTAKT

[nicolaslekai@gmail.com](mailto:nicolaslekai@gmail.com)

Backtest-Metriken: mittlerer absoluter Fehler (MAE) und RMSE der wöchentlichen ITS-Belegung in Prozentpunkten, Test auf den letzten 52 Wochen (nicht im Training). Skill =  $1 - \text{MAE}_{\text{Modell}} / \text{MAE}_{\text{Persistenz}}$ . Modelle: scikit-learn ElasticNetCV, HistGradientBoostingRegressor, MLPRegressor. Datenquellen: DIVI-Intensivregister, RKI (AGI, ICOSARI) — öffentlich. Stand 18. Juli 2026.